

Ceres Diagnostico - Sprint MVP

Roteiro de Apresentação | 17 slides | 20 minutos

SLIDE 01 - CAPA

30 seg

Ceres Diagnostico — Sprint Review

FALA

Boa tarde. Sou Namem Rachid, aluno de Engenharia da Computacao do IFMT Cuiaba. Vou apresentar o Ceres Diagnostico — sistema embarcado de deteccao precoce de doencas no tomateiro. Em vinte minutos: o problema, o que construímos, onde chegamos e onde erramos.

DICA

-> Fala curta. Postura confiante. Deixe o slide dark falar por si.

SLIDE 02 - ROADMAP

1 min

De onde viemos e para onde vamos

FALA

Quatro sprints concluídos — um ano de desenvolvimento. Sprint 0: motor de diagnostico por perguntas. Sprint 1: treinamento da IA e pipeline MQTT. Sprint 2: IA embarcada no ESP32-S3, validada em 692ms. Sprint MVP — estamos aqui — app completo e hardware real. Proximos passos: camera embarcada e dataset brasileiro.

DICA

-> Aponte para os marcos no roadmap. Pause em "estamos aqui".

SLIDE 03 - O PROBLEMA

1 min

O agricultor perde antes de saber o que perdeu

FALA

Um tomateiro doente nao grita. Ele murcha em silencio enquanto a doenca avanca. A requeima pode destruir 100% da lavoura sem tratamento. Diagnostico depende de agronomo inacessivel ao pequeno produtor. Existem 10 doencas dificeis de separar a olho nu. E a internet que permitiria diagnostico digital nao chega na lavoura.

DICA

-> Fale devagar nos tres pilares: acesso ao especialista, volume de doencas e infraestrutura.

SLIDE 04 - OBJETIVO INICIAL

45 seg

Tres pilares — um sistema integrado

FALA

O objetivo inicial era uma solucao em tres camadas. Hardware: ESP32-S3 com camera OV5640, IA embarcada sem internet. App: Flutter com TFLite local sincronizado com a nuvem. Backend: Django REST no Railway com historico e alertas MQTT. Esse era o plano — em breve vou mostrar o que mudou.

DICA

-> Slide rapido. Plante a semente dos pivos sem revelar ainda.

SLIDE 05 - DIAGNOSTICO

1 min

Foto a folha. Saiba o que esta acontecendo.

FALA

O produtor fotografa a folha, a IA classifica em menos de 2 segundos, e o resultado aparece com doenca, confianca, top-3 e recomendacao de tratamento. Com internet: resultado sincroniza com Railway, historico na nuvem, mapa em tempo real. Sem internet: IA roda no celular em menos de 1 segundo, nenhum dado sai do dispositivo. 98,43% de acuracia. 638KB. Funciona em qualquer lavoura.

DICA

-> Este e o slide do PRODUTO — fale como se estivesse vendendo. Cloud e offline sao diferenciais claros.

SLIDE 06 - 10 CLASSES

45 seg

9 doencas + saudavel

FALA

O modelo classifica 10 categorias: requeima, septoriose, pinta preta, mancha alvo, mofo foliar, vira-cabeca, mosaico, acaro de bronzamento, mancha bacteriana e saudavel. Dataset PlantVillage — 18.160 imagens, CC BY 4.0. Aqui fica evidente por que o gap existe: todas as fotos tem fundo cinza uniforme, totalmente diferente de uma lavoura real.

DICA

-> Slide visual. Deixe as fotos falarem. Conecte ao proximo slide: "o modelo aprendeu essas imagens de lab".

SLIDE 07 - O MODELO

1,5 min

Unico modelo que cabe no chip

FALA

Para rodar IA num microcontrolador de 80 reais, a escolha e critica. ResNet-50: 100MB — nao cabe no ESP32-S3. YOLO: detecta objetos, nao classifica folha — ferramenta errada. EfficientNet: 20MB, latencia acima de 2s em MCU — inviavel. MobileNetV2 INT8 calibrado: 638KB, 692ms, 98,43%. Unico que fecha todas as restricoes ao mesmo tempo.

DICA

-> Aponte para a linha dourada na tabela. Diga: "e o unico que fecha TODAS as restricoes simultaneamente".

95,76% no lab -> 20,77% em campo real

FALA

95,76% de acuracia no PlantVillage — imagens de laboratorio, fundo cinza. Testamos com o PlantDoc, 1.353 imagens de campo real: caiu para 20,77%. Queda de 75 pontos. A causa: o modelo aprendeu o fundo cinza como feature, nao a doenca. Fenomeno em 42 trabalhos — Mohanty 2016: 99% lab e 31% campo. Singh 2020: trocar o fundo recupera 40pp. Decisao: documentar honestamente. Proximo passo: dataset com condicoes brasileiras.

DICA

-> Slide mais importante. Fale com calma. "Documentamos honestamente" mostra maturidade — nao e fracasso, e resultado.

5 experimentos para fechar o gap

FALA

Exp A: Edge Impulse sem calibracao — 62%, descartado. Exp B: TF local duas fases + INT8 calibrado — 98,43% lab, 20,77% campo, modelo base. Exp C: 177k sinteses rembg — 20,24%, pior que B, descartado. Exp D: fine-tuning com 677 imagens reais do PlantDoc — 30,43%, +10pp, melhor resultado. Exp E: Focal Loss + dataset India — 27,65%, abaixo do D, descartado. Conclusao: dado real supera dado sintetico.

DICA

-> Percorra linha por linha. Pause no Exp D. Encerre: "dados reais > sinteticos — isso guia os proximos passos".

Resultados do Sprint MVP — em numeros

FALA

98,43% de acuracia (18-30% campo documentado). 692ms de latencia no ESP32-S3. 638KB de modelo INT8 no dispositivo. 10/10 acertos no benchmark offline. 88.949 imagens de treino com augmentation x6. 184 eventos IoT registrados durante os testes.

DICA

-> Slide de impacto — deixe os numeros respirarem. Escolha 2-3 e conecte ao problema inicial.

3 pivos que definiram o MVP

FALA

Pivo 1 ESP32-S3: camera OV5640 nao chegou no prazo por custo. ESP32-S3 ficou como prova de conceito — 692ms validados. App mobile virou produto principal end-to-end. Pivo 2 Experimentos: Exp C com 177k sinteses falhou — pior que B. Dado real vence sintetico. Pivo 3 Gap lab-campo: documentamos o fenomeno honestamente. Proximo: dataset proprio de MT.

DICA

-> Nao se desculpe pelos pivos. Explique a logica de cada decisao — soa como mercado de trabalho real.

SLIDE 12 - O QUE CONSTRUIMOS

1 min

Sprint 1 vs Sprint MVP

FALA

Sprint 1 tinha: motor por perguntas, API sem camera, modelo na nuvem sem offline. O Sprint MVP entregou: foto com IA em menos de 2 segundos, 98,43% de acuracia, offline completo no celular, app com mapa, historico e enciclopedia, e ESP32-S3 monitorando ambiente em tempo real via MQTT.

DICA

-> Leia as colunas lado a lado. Finalize: "entregamos mais do que o planejado".

SLIDE 13 - APP CERES

1,5 min

Flutter completo — 4 telas

FALA

Tela 1 Diagnostico: TFLite local, resultado offline em menos de 1 segundo. Tela 2 Historico IoT: historico sincronizado com sensores ESP32, temperatura e umidade em tempo real. Tela 3 Enciclopedia: fichas das 10 doencas. Tela 4 Mapa: geolocalizacao de ocorrencias. Backend Django REST em producao no Railway, JWT, SQLite local com Drift.

DICA

-> "Em producao" e a palavra-chave — nao e prototipo. Railway + offline mostra que funciona em condicoes reais.

SLIDE 14 - HARDWARE IoT

1,5 min

ESP32-S3 — sentinela da lavoura

FALA

Esse e o hardware real do projeto — ESP32 com DHT22 no vaso e sensor capacitivo enterrado no solo. A cada 30 segundos mede temperatura, umidade do ar e umidade do solo, e envia tudo via MQTT para a nuvem. O app exibe em tempo real. Latencia do sensor ate o app: menos de 2 segundos. Custo total do no: ~R\$80.

DICA

-> Aponte para a foto no slide — o setup real esta ali. Se tiver o ESP32 fisico na mao, melhor ainda.

SLIDE 15 - CONCLUSAO

1 min

TinyML agricola funciona. O gargalo e o dado.

FALA

Duas conclusoes. Viabilidade tecnica: MobileNetV2 INT8, 638KB, 692ms, hardware de ~R\$80. Roda no ESP32-S3. O gap de 20-30% em campo nao e fracasso — e fenomeno documentado. Mohanty 2016 tinha 31%, Singh 2020 mostrou que trocar o fundo recupera 40pp. O gargalo nao e o algoritmo nem o hardware. E o dado. Dataset brasileiro de tomateiro e o proximo passo.

DICA

-> Diga as duas conclusoes devagar — uma pause entre elas. Ultima frase: "o gargalo e o dado, nao o hardware" — deixe no ar.

SLIDE 16 - DEMO

3 min

Demonstracao ao vivo

FALA

Tres cenarios. Cloud: foto de requeima, resultado 94% em menos de 2 segundos sincronizado com Railway. Offline: foto de folha saudavel, classificacao em menos de 1 segundo sem nenhuma conexao. Mapa: 30 ou mais pins de ocorrencias registrados nos testes em MT. [Abrir app ao vivo] — se algo falhar, gravacao de backup disponivel.

DICA

-> Prepare antes: app aberto, WiFi ligado e modo aviao prontos para trocar rapidamente. Mencione o backup antes de comecar — mostra preparo. 3 minutos passam rapido.

SLIDE 17 - PROXIMOS PASSOS

1 min

O caminho ate o campo real

FALA

Cinco passos. Um: camera OV5640 no ESP32-S3 — diagnostico autonomo sem celular na lavoura. Dois: dataset brasileiro de tomate — primeiras imagens reais de MT, com condicoes locais. Tres: retreino com dados locais para reduzir o gap de laboratorio. Quatro: validacao com tomaticultores de Mato Grosso em campo real. Cinco: publicar em conferencia de IA agricola.Codigo em github.com/Namem/extensao2, API em ceres.up.railway.app. Obrigado.

DICA

-> "Podem acessar agora" — mostra que e real e esta no ar. Abra para perguntas.