

Roteiro de Apresentação

Sprint Review 2 — Ceres Diagnóstico

TCC Engenharia da Computação · IFMT Cuiabá · Maio / 2026

Tempo total	~15 minutos
Slides	10 slides
Ritmo	Slides 6 e 7 são os mais densos — não apresse. No slide 5, passe rápido em A e B, foque em C, D e E.
Se estourar	Corte o slide 8 (gap) pela metade — cite os 4 fatores em 30 segundos.

SLIDE 1 — CAPA

■ Tempo estimado: 20 segundos

O QUE DIZER

Boa tarde. Meu nome é Namem, e esse é o Sprint Review 2 do Ceres Diagnóstico — meu TCC de Engenharia da Computação aqui no IFMT Cuiabá. O projeto constrói um sistema embarcado de detecção de doenças no tomateiro usando inteligência artificial em microcontrolador, sem depender de internet.

■ Dica: Fale com calma. Olhe para a banca, não para o slide.

SLIDE 2 — VISÃO GERAL

■ Tempo estimado: 1 minuto

O QUE DIZER

O problema: o produtor rural, especialmente em Mato Grosso, não tem acesso rápido a diagnóstico de doenças. Uma doença não detectada pode destruir 100% da safra.

A solução é um ESP32-S3 — um microcontrolador, que é basicamente um computador do tamanho de uma moeda — com câmera acoplada e inteligência artificial embarcada. O produtor aponta para a folha e recebe o diagnóstico no campo, sem internet.

O sistema publica os dados via MQTT — um protocolo de comunicação leve para IoT, Internet das Coisas. Esses dados são recebidos pelo Django, o servidor web em Python que desenvolvemos, persistidos no PostgreSQL e exibidos no app Flutter.

As sprints 0 e 1 já foram apresentadas — esse slide é só contexto para quem não acompanhou.

TERMOS TÉCNICOS DESTES SLIDES

ESP32-S3	Microcontrolador da Espressif com WiFi, Bluetooth e 8MB de memória PSRAM. É o 'cérebro' do dispositivo de campo.
Microcontrolador	Computador compacto em um único chip — processa, armazena e controla periféricos com pouquíssima energia.
MQTT	Protocolo de mensagens leve para IoT. Usa apenas 2 bytes de cabeçalho vs ~820 bytes do HTTP. Projetado para redes instáveis.
IoT	Internet das Coisas — dispositivos físicos conectados que coletam e enviam dados.
Django	Framework web em Python usado para construir o servidor REST que recebe, processa e expõe os dados via API.
Flutter	Framework do Google para criar apps móveis multiplataforma (Android/iOS) com um único código.

■ *Dica: Sprint 0 e 1 = contexto rápido. Não entre em detalhes técnicos aqui.*

SLIDE 3 — O QUE PROMETEMOS

■ **Tempo estimado: 1 minuto e 30 segundos**

O QUE DIZER

Na Sprint Review 1, a promessa original era entregar o app Flutter. Tomamos uma decisão técnica: com o hardware ESP32-S3 em mãos e o modelo de IA pronto, fazia mais sentido validar a pilha completa de IA e IoT antes de construir uma interface sem dados reais. O Flutter sem dados reais do hardware seria só interface sem substância.

As duas metas desta sprint foram: primeiro, entender por que o modelo vai bem no laboratório mas mal no campo — e tentar melhorar isso. Segundo, validar o pipeline IoT de ponta a ponta em hardware real, do sensor ao banco de dados.

TERMOS TÉCNICOS DESTE SLIDE

Pipeline IoT	Caminho completo dos dados: ESP32 coleta → publica via MQTT → servidor recebe → banco de dados armazena → API entrega.
API REST	Interface que permite ao app e a outros sistemas buscar dados do servidor via HTTP com autenticação.

■ *Dica: Deixe claro que foi uma decisão consciente, não um atraso.*

SLIDE 4 — DATASET PLANTVILLAGE

■ **Tempo estimado: 1 minuto e 30 segundos**

O QUE DIZER

Para treinar qualquer modelo de inteligência artificial, precisamos de um dataset — um conjunto de dados rotulados, nesse caso fotos de folhas de tomate com a doença identificada.

Usamos o PlantVillage, criado por Hughes e Salathé em 2015. O título do paper é 'An open access repository of images on plant health to enable the development of mobile disease diagnostics'. É o maior benchmark público de doenças de plantas — benchmark significa conjunto de referência usado pela comunidade científica para comparar resultados.

São 18 mil imagens coletadas em laboratório com fundo controlado. Aplicamos augmentation — multiplicação dos dados com variações como rotação, flip e mudança de brilho — e chegamos a 88 mil imagens de treino. Licença CC BY 4.0, uso acadêmico e comercial permitido.

Detalhe importante: esse fundo cinza uniforme de laboratório é a raiz do problema que investigamos nessa sprint inteira.

TERMOS TÉCNICOS DESTE SLIDE

Dataset	Conjunto de dados rotulados usado para treinar e avaliar modelos de IA.
Benchmark	Conjunto de referência padrão da comunidade científica para comparar resultados entre trabalhos diferentes.
Augmentation	Técnica de multiplicar dados aplicando variações nas imagens: rotação, flip, zoom, brilho, saturação.
CC BY 4.0	Licença Creative Commons que permite uso, redistribuição e modificação com atribuição ao autor — inclusive comercialmente.
Split 70/15/15	Divisão do dataset: 70% para treino, 15% para validação durante o treino, 15% para teste final (dados nunca vistos).

■ *Dica: Enfatize o fundo cinza — é a ponte para o próximo slide.*

SLIDE 5 — JORNADA A → E

■ **Tempo estimado: 2 minutos e 30 segundos**

O QUE DIZER

Nessa sprint conduzimos 5 experimentos. Vou passar rápido nos dois primeiros, que são da sprint anterior, e focar nos três novos.

Exp A: treinamos na nuvem pelo Edge Impulse usando MobileNetV2 — uma arquitetura de rede neural do Google otimizada para dispositivos pequenos. O problema foi a quantização INT8 automática: quantização é o processo de comprimir o modelo de números de 32 bits para 8 bits — reduz o tamanho drasticamente, mas sem calibração perdeu 30 pontos percentuais de acurácia. Descartado.

Exp B: treinamos localmente com TensorFlow no WSL2 — subsistema Linux dentro do Windows — usando a GPU RTX 3060 Ti. A quantização desta vez foi calibrada: passamos 50 amostras reais durante a compressão. Resultado: 98% de acurácia, 639 KB. Esse virou a base do projeto.

Exp C: tentamos resolver o gap de campo com augmentação sintética de fundo — 177 mil composições, 650 minutos de GPU. Zero pontos de ganho em campo. O rembg gerou artefatos de borda que o modelo aprendeu como feature falsa — isso motivou o Exp D.

Exp D: misturamos 677 fotos reais de campo ao treinamento. Fine-tuning — ajuste fino do modelo já treinado. Resultado: +10 pontos percentuais em imagens nunca vistas.

Exp E: adicionamos Focal Loss — uma função de perda que prioriza exemplos difíceis no treino — e augmentação de cor agressiva. +16 pontos na Índia, +8,5 em Bangladesh. Esse é o modelo final: 638 KB.

TERMOS TÉCNICOS DESTE SLIDE

MobileNetV2	Arquitetura de rede neural do Google (Howard et al., 2017) otimizada para dispositivos com restrição de memória.
Quantização INT8	Compressão do modelo: converte pesos de float32 (4 bytes) para int8 (1 byte). Reduz tamanho ~4x com pequena perda de acurácia SE calibrada.
Calibração	Processo de passar amostras reais pelo modelo durante a quantização para que ele aprenda a ajustar os valores comprimidos.
TensorFlow	Principal biblioteca de machine learning do Google. Usada para definir, treinar e exportar modelos de IA.
WSL2	Windows Subsystem for Linux 2 — ambiente Linux dentro do Windows com acesso direto à GPU via CUDA.
GPU / CUDA	GPU (placa de vídeo) processa milhares de operações em paralelo — essencial para treinar redes neurais rapidamente. CUDA é a interface da NVIDIA.
Fine-tuning	Ajuste fino: continuar o treinamento de um modelo já treinado com novos dados específicos, sem partir do zero.
Focal Loss	Função de perda (Lin et al., 2017, Facebook AI Research) que dá 4× mais peso de aprendizado para exemplos que o modelo erra com alta confiança.

rembg

Ferramenta que usa a rede U2-Net para remover o fundo de imagens (segmentação semântica pixel a pixel).

■ Dica: A linha do rodapé em laranja explica por que C falhou — não precisa elaborar muito aqui, já está na tabela.

SLIDE 6 — VALIDAÇÃO EM 3 DATASETS

■ Tempo estimado: 2 minutos

O QUE DIZER

O Exp D misturou 677 fotos reais do PlantDoc ao treinamento. Com isso, o modelo passou de ~20% para 30,43% em imagens de campo nunca vistas — 10 pontos de ganho real.

Para garantir que esse ganho não era específico ao PlantDoc, validamos em dois datasets completamente independentes — nunca tocados em nenhum experimento.

O Tomato-Village: 217 fotos de Rajasthan, na Índia. O Daffodil BD: 1.616 fotos de Bangladesh. Nenhum desses dados existia durante o treino.

O Exp E — Focal Loss com augmentação de cor — melhorou ainda mais: +16 pontos na Índia, +8,5 pontos em Bangladesh comparado ao Exp D. Esse é o modelo final.

A linha do PlantDoc está marcada como não comparável porque o Exp D treinou nesse split — seria comparação injusta.

TERMOS TÉCNICOS DESTE SLIDE

Dataset independente	Conjunto de dados que não foi usado em nenhuma etapa do treinamento — garante que o resultado não é memorização.
PlantDoc	Dataset de campo real com ~1.353 fotos, coletadas nos EUA e Europa, usado como validação de campo.
Tomato-Village	217 fotos de tomateiros em Rajasthan, Índia. Nunca usado no treino — validação independente geográfica.
Daffodil BD	1.616 fotos de Bangladesh coletadas com iPhone 11 em campo aberto. Terceira validação independente.
Δ (delta)	Diferença em pontos percentuais entre Exp D e Exp E no mesmo dataset.

■ Dica: Esse slide é o ponto mais forte da sprint — mostre com segurança os números +16pp e +8,5pp.

SLIDE 7 — COMPARAÇÃO COM LITERATURA

■ Tempo estimado: 1 minuto e 30 segundos

O QUE DIZER

Esses resultados não são uma anomalia — é o padrão documentado na literatura.

Mohanty et al. em 2016, no *Frontiers in Plant Science*, criou o primeiro trabalho relevante usando deep learning para doenças de plantas. 99% no laboratório, ~31% em campo real. Nunca embarcou em hardware.

Singh et al. em 2020, no *IEEE Access*, foi o primeiro a comparar sistematicamente laboratório versus campo, chegando a 55% usando fotos reais. Também sem hardware embarcado.

O diferencial do Ceres: 638 KB rodando dentro de um ESP32-S3 — nenhum dos dois trabalhos embarcou a solução em microcontrolador. MobileNetV2 do Howard et al., 2017, é a única arquitetura que consegue esse nível de acurácia dentro das restrições de memória de um microcontrolador.

TERMOS TÉCNICOS DESTE SLIDE

Deep learning	Aprendizado profundo — redes neurais com muitas camadas que aprendem representações hierárquicas dos dados.
Frontiers in Plant Science	Periódico científico de acesso aberto, Qualis B1 na área de Ciências Agrárias.
IEEE Access	Periódico multidisciplinar do IEEE, Qualis A2, acesso aberto.
30,43% vs 55% (Singh)	Nossa acurácia de campo é menor, mas com modelo 638KB em microcontrolador. Singh usou servidor com modelo de dezenas de MB.

■ *Dica: Se perguntarem '30% é ruim': 'É o padrão da área para sistemas sem servidor. O diferencial é funcionar offline em 638KB.'*

SLIDE 8 — POR QUE O GAP LAB-CAMPO EXISTE?

■ **Tempo estimado: 1 minuto e 30 segundos**

O QUE DIZER

Por que o gap laboratório-campo existe mesmo depois de todos esses experimentos? São quatro fatores independentes.

Primeiro: o fundo. PlantVillage tem fundo cinza uniforme — o modelo aprende o fundo como parte da identidade da doença. Resolvido parcialmente pelo Exp D.

Segundo: iluminação e câmera. Luz solar direta, sombras e câmeras de celular criam uma distribuição visual completamente diferente do laboratório. O Exp E ataca isso com augmentação de cor.

Terceiro: variedade geográfica. Uma cultivar de tomate de Rajasthan tem morfologia foliar diferente de uma cultivar americana ou mato-grossense. O modelo nunca viu folhas indianas ou brasileiras durante o treino.

Quarto: estágio fenológico — a fase de desenvolvimento da planta. Folha jovem e folha velha da mesma planta doente parecem diferentes, e o laboratório não cobre isso.

Resolver só um fator não fecha o gap. A validação definitiva é com produtores de Sorriso-MT — fotos brasileiras, condições reais do Mato Grosso.

TERMOS TÉCNICOS DESTE SLIDE

Gap lab-campo	Diferença de desempenho entre o modelo no laboratório (controlado) e no campo (condições reais).
Distribuição visual	Padrão estatístico dos pixels de um conjunto de imagens. Laboratório e campo têm distribuições diferentes.
Cultivar	Variedade específica de uma planta desenvolvida por seleção ou melhoramento genético.
Estágio fenológico	Fase de desenvolvimento da planta: germinação, crescimento vegetativo, floração, frutificação etc.
Domain shift	Mudança de domínio — quando o modelo é testado em condições diferentes das do treinamento.

■ *Dica: Se o tempo apertar: cite os 4 fatores rapidamente e vá direto para a frase final sobre Sorriso-MT.*

SLIDE 9 — PRÓXIMOS PASSOS

■ **Tempo estimado: 1 minuto**

O QUE DIZER

A cadeia de validação do modelo tem quatro níveis. Nível 1, laboratório: feito, 98%. Nível 2, campo com datasets públicos internacionais: feito, 30% PlantDoc. Faltam os níveis 3 e 4.

Nível 3 é a Sprint 2: embarcar o modelo TFLite Micro — formato do TensorFlow para microcontroladores — no ESP32-S3 com câmera OV5640. A meta é latência menor que 300 milissegundos por inferência. Depende da chegada do hardware.

Nível 4 é a Sprint 3: validação com produtores de Sorriso-MT — a métrica que vai para o TCC como resultado final. Paralelamente, o app Flutter entra nessa sprint.

TERMOS TÉCNICOS DESTE SLIDE

TFLite Micro	Versão do TensorFlow Lite para microcontroladores. Roda modelos .tflite com pouquíssima RAM e sem sistema operacional.
Inferência	O ato do modelo analisar uma nova imagem e produzir uma classificação. Diferente do treino — aqui ele só prevê.
Latência	Tempo entre a captura da imagem e o resultado da classificação. Meta: < 300ms no ESP32-S3.
OV5640	Sensor de câmera 5MP com interface MIPI/DVP — compatível com ESP32-S3, captura frames em resolução suficiente para inferência.
Sorriso-MT	Município do Mato Grosso, maior produtor de soja do Brasil e importante polo de tomateiro — contexto real do sistema.

■ *Dica: Mencione que o Flutter não sumiu do roadmap — só foi reordenado.*

SLIDE 10 — ENCERRAMENTO

■ **Tempo estimado: 30 segundos**

O QUE DIZER

Resumindo a Sprint 2: cinco experimentos com metodologia científica completa — incluindo dois resultados negativos, os experimentos A e C, que têm tanto valor acadêmico quanto os positivos porque documentam o que não funciona e por quê.

Modelo final: Exp E, 638 KB, validado em três continentes. O gap laboratório-campo está documentado com respaldo na literatura. O próximo marco é TFLite Micro no ESP32-S3 com câmera real.

Obrigado — fico à disposição para perguntas.

■ *Dica: Fale com calma. Não apresse o encerramento — é a última impressão.*

PERGUNTAS PROVÁVEIS DA BANCA

■ 30% de acurácia em campo é um bom resultado?

Sim — é o padrão da área para sistemas embarcados offline. Mohanty et al. 2016 obteve ~31% em campo com um modelo de servidor. O diferencial do Ceres é que roda em 638KB dentro de um microcontrolador, sem internet, no campo. Nenhum dos trabalhos de referência embarcou a solução em hardware real.

■ O que pode ser feito para melhorar a acurácia em campo?

A principal alavanca é coletar fotos reais locais — tomateiros de Mato Grosso, nas condições reais de Sorriso. Isso está planejado como Nível 4 da cadeia de validação. Tecnicamente, domain adaptation — técnicas que treinam o modelo para ser invariante à diferença entre laboratório e campo — é a direção mais promissora na literatura. Singh et al. 2020 confirmam: dados reais de campo superam qualquer augmentação sintética.

■ MobileNetV2 é o limite da arquitetura para o ESP32-S3?

Para o ESP32-S3 N16R8 com 8MB de PSRAM, MobileNetV2 96×96 INT8 é uma das poucas arquiteturas que cabem com folga — 638KB de modelo mais aproximadamente 2–3MB de buffers em tempo de inferência. EfficientNet-Lite0 e MobileNetV3-Small também caberiam com resultados similares. O gargalo real não é a arquitetura — é a resolução de entrada: 96×96 pixels é muito baixo para capturar detalhes finos de textura foliar. Com 224×224 a acurácia de campo provavelmente subiria, mas não cabe na memória do ESP32-S3.

■ Se fosse um sistema em nuvem, sem o ESP32, a acurácia seria melhor?

Sim, substancialmente. Sem a restrição de 638KB, poderíamos usar ResNet50 ou EfficientNetB4 com entrada de 224×224 ou maior — a literatura mostra 55–65% em campo real com esses modelos. Mas o requisito central do projeto é funcionar offline, no campo, sem internet e sem custo de infraestrutura. Um produtor em campo no Mato Grosso muitas vezes não tem sinal. A restrição de tamanho não é uma limitação — é o requisito que define o projeto.

■ Por que usaram o PlantVillage e não outro dataset?

PlantVillage é o benchmark padrão da área, com licença aberta CC BY 4.0, usado pelos dois trabalhos de referência — Mohanty 2016 e Singh 2020 — o que permite comparação direta de resultados. Com 18.160 imagens e 10 classes do tomateiro exatamente mapeadas para o escopo do Ceres, é o único dataset público que atende simultaneamente os requisitos de tamanho, licença e cobertura de doenças.

■ Resultados negativos (Exp A e C) têm valor científico?

Sim — documentar o que não funciona e por quê é parte essencial do método científico. O Exp A mostrou que quantização sem calibração perde 30 pontos percentuais, informação útil para qualquer trabalho futuro com TinyML. O Exp C mostrou que augmentação sintética de fundo não resolve o gap de campo, contradizendo a hipótese inicial e motivando o Exp D. Ambos estão documentados com análise de causa.

GLOSSÁRIO RÁPIDO — USE SE PERGUNTAREM

Dataset: Conjunto de dados rotulados para treinar IA	Acurácia: Percentual de acertos do modelo
Quantização INT8: Compressão do modelo de 32 bits para 8 bits	Fine-tuning: Ajuste fino de um modelo já treinado com novos dados
Focal Loss: Função que prioriza exemplos difíceis no treino	Inferência: O modelo analisando uma imagem nova e dando um resultado
TFLite Micro: TensorFlow comprimido para rodar em microcontroladores	MQTT: Protocolo de comunicação leve para IoT
MobileNetV2: Arquitetura de rede neural otimizada para dispositivos pequenos	Augmentation: Multiplicar dados aplicando variações nas imagens
Benchmark: Conjunto de referência padrão da comunidade científica	Domain shift: Modelo testado em condições diferentes do treino
Gap lab-campo: Diferença de acurácia entre laboratório e campo real	PSRAM: Memória RAM externa no ESP32-S3 — 8MB, onde o modelo é carregado
WSL2: Linux dentro do Windows, com acesso à GPU para treino	PlantVillage: Dataset de 18.160 imagens de doenças de plantas — Hughes & Salathé 2015